

**ĐẠI HỌC QUỐC GIA TP HCM**  
**TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN**  
**KHOA CÔNG NGHỆ PHẦN MỀM**

**KHÓA LUẬN TỐT NGHIỆP**

**XÂY DỰNG HỆ THỐNG LỌC RÁC CHO HỆ THỐNG  
PHÁT HIỆN TIN NÓNG TỪ CÁC TRANG TIN TỨC**

**Giảng viên hướng dẫn: TS. Huỳnh Ngọc Tín**

**Sinh viên 1: Hoàng Anh Minh**

**MSSV: 13520505**

**Lớp: CNPM08**

**Khóa: 2013-2017**

**Sinh viên 2: Lâm Tuấn Anh**

**MSSV: 13520020**

**Lớp: CNPM08**

**Khóa: 2013-2017**

**TP HỒ CHÍ MINH – Tháng 6, năm 2017**

**ĐẠI HỌC QUỐC GIA TP HCM**  
**TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN**  
**KHOA CÔNG NGHỆ PHẦN MỀM**

**KHÓA LUẬN TỐT NGHIỆP**

**XÂY DỰNG HỆ THỐNG LỌC RÁC CHO HỆ THỐNG  
PHÁT HIỆN TIN NÓNG TỪ CÁC TRANG TIN TỨC**

Giảng viên hướng dẫn: **TS. Huỳnh Ngọc Tín**

Sinh viên 1: **Hoàng Anh Minh**

MSSV: **13520505**

Lớp: **CNPM08**

Khóa: **2013-2017**

Sinh viên 2: **Lâm Tuấn Anh**

MSSV: **13520020**

Lớp: **CNPM08**

Khóa: **2013-2017**

Đơn vị đồng hành: **VCCorp**

**TP HỒ CHÍ MINH – Tháng 12, năm 2017**

## **DANH SÁCH HỘI ĐỒNG BẢO VỆ KHÓA LUẬN**

Hội đồng chấm khóa luận tốt nghiệp, thành lập theo Quyết định số .....  
ngày ..... của Hiệu trưởng Trường Đại học Công nghệ Thông tin.

1. .... – Chủ tịch.
2. .... – Thư ký.
3. .... – Ủy viên.
4. .... – Ủy viên.

[illegible]

[illegible]

# LỜI CẢM ƠN

Trước tiên, em xin gửi lời cảm ơn chân thành đến TS. Huỳnh Ngọc Tín, người đã tận tình giúp đỡ, trực tiếp chỉ bảo, hướng dẫn em trong suốt quá trình thực hiện khóa luận tốt nghiệp này. Những kinh nghiệm, lời nhận xét và chia sẻ của thầy truyền đạt cho em thật sự rất quý báu và ý nghĩa.

Em cũng gửi lời cảm ơn đến quý thầy cô đang công tác tại Trường Đại học Công Nghệ Thông Tin nói chung và Khoa Khoa học máy tính nói riêng đã dạy dỗ, truyền đạt những kiến thức, kinh nghiệm vô cùng quý báu, giúp em vận dụng trong quá trình thực tập.

Ngoài ra, xin cảm ơn sự hỗ trợ quý giá của các bạn trong nhóm AdTech tại công ty VCCorp trong quá trình xây dựng hệ thống.

Cuối cùng, em xin chúc thầy luôn mạnh khỏe và đạt nhiều thành công trong cuộc sống.

Tp. HCM, tháng 12 năm 2017

Sinh viên thực hiện

Hoàng Anh Minh

Lâm Tuấn Anh

# Mục lục

Mục lục	v
Danh mục các ký hiệu, thuật ngữ và chữ viết tắt	ix
Danh sách bảng	x
Danh sách hình vẽ	xi
<b>TÓM TẮT KHÓA LUẬN</b>	<b>1</b>
<b>Chương 1. MỞ ĐẦU</b>	<b>3</b>
1.1 Dẫn nhập . . . . .	3
1.2 Mục tiêu đề tài . . . . .	3
1.3 Nội dung thực hiện . . . . .	4
1.4 Phạm vi đề tài . . . . .	4
1.5 Cấu trúc báo cáo . . . . .	4
<b>Chương 2. BÀI TOÁN LỌC RÁC TIN TỨC VÀ CÁC PHƯƠNG PHÁP TIẾP CẬN PHỔ BIẾN</b>	<b>6</b>
2.1 Mở đầu . . . . .	6
2.2 Giới thiệu bài toán . . . . .	6
2.2.1 Các khái niệm cơ bản . . . . .	6
2.2.2 Bài toán phân lớp văn bản . . . . .	7
2.2.3 Bài toán lọc rác tin tức . . . . .	7
2.2.4 Phát biểu bài toán lọc rác tin tức cho hệ thống phát hiện tin nóng	8
2.3 Các nghiên cứu liên quan . . . . .	8
2.4 Giới thiệu một số phương pháp trừu tượng hóa dữ liệu văn bản . . . . .	8

2.5	Các phương pháp tiếp cận phổ biến . . . . .	10
2.5.1	Thuật toán phân lớp Support Vector Machine (SVM) . . . . .	10
2.5.1.1	Ý tưởng . . . . .	10
2.5.1.2	Minh họa thuật toán . . . . .	10
2.5.1.3	Mã giả . . . . .	12
2.5.1.4	Ưu điểm, hạn chế . . . . .	12
2.5.2	Thuật toán gom cụm có Boost trọng số cho Named Entity . . .	13
2.5.2.1	Ý tưởng . . . . .	13
2.5.2.2	Minh họa thuật toán . . . . .	13
2.5.2.3	Mã giả . . . . .	14
2.5.2.4	Ưu điểm, hạn chế . . . . .	15
2.5.3	Thuật toán Locality Sensitive Hashing . . . . .	16
2.5.3.1	Ý tưởng . . . . .	16
2.5.3.2	Minh họa cách tính hash code cho LSH . . . . .	16
2.5.3.3	Mã giả . . . . .	17
2.5.3.4	LSH cải tiến . . . . .	18
2.6	Giới thiệu một số độ đo đánh giá phân lớp . . . . .	19
2.6.1	Khoảng cách cục bộ và toàn cục (Intra-cluster và Inter-cluster distance) . . . . .	19
2.6.2	Độ đo Dunn index . . . . .	20
2.6.3	Hệ số Silhouette (Silhouette coefficient) . . . . .	21
2.6.4	Độ đo Purity . . . . .	21
2.7	Xếp hạng cụm . . . . .	22
2.8	Kết chương . . . . .	23
<b>Chương 3. HIỆN THỰC HỆ THỐNG PHÁT HIỆN TIN NÓNG</b>		<b>24</b>
3.1	Mở đầu . . . . .	24
3.2	Mô hình hệ thống . . . . .	24
3.3	Phân hệ thu thập dữ liệu (Data Streaming) . . . . .	25
3.4	Phân hệ tiền xử lý dữ liệu (Data Preprocessor) . . . . .	25
3.5	Phân hệ phân loại tin tức . . . . .	25



3.6	Phân hệ phân loại loại rác . . . . .	26
3.7	Thiết kế hệ thống . . . . .	26
3.8	Cài đặt hệ thống . . . . .	28
3.8.1	Các package . . . . .	28
3.8.2	Cơ sở dữ liệu MongoDB . . . . .	29
3.8.2.1	Collection News . . . . .	30
3.8.2.2	Collection HashCode . . . . .	30
3.8.3	Cơ sở dữ liệu MySQL . . . . .	31
3.8.3.1	Bảng User . . . . .	31
3.9	Giao diện . . . . .	31
3.9.1	Giao diện danh sách tin đã phân lớp . . . . .	32
3.9.2	Giao diện phân lớp tin . . . . .	32
3.9.3	Giao diện thống kê dữ liệu phân lớp . . . . .	33
3.10	Kết quả . . . . .	33
3.11	Kết quả . . . . .	33
3.12	Kết chương . . . . .	36
<b>Chương 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ</b>		<b>37</b>
4.1	Mở đầu . . . . .	37
4.2	Tổng quan về bộ dữ liệu . . . . .	37
4.3	Thiết lập thực nghiệm, cách đánh giá . . . . .	38
4.4	Kết quả thực nghiệm . . . . .	38
4.4.1	Kết quả train model phân loại tin tức . . . . .	38
4.4.1.1	Kết quả dựa trên nội dung của tin của tập mẫu . . . . .	39
4.4.1.2	Kết quả dựa trên tiêu đề của tin của tập mẫu . . . . .	41
4.4.2	Kết quả train model phân loại loại tin rác . . . . .	43
4.5	Nhận xét . . . . .	45
4.5.1	Nhận định về các thuật toán phân lớp cho bài toán . . . . .	45
4.6	Kết chương . . . . .	45
<b>KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN</b>		<b>46</b>
Kết quả đạt được . . . . .		46

Hướng phát triển . . . . .	46
<b>TÀI LIỆU THAM KHẢO</b>	<b>48</b>
<b>Phụ lục. Giới thiệu về thư viện Apache Lucene</b>	<b>50</b>

# Danh mục các ký hiệu, thuật ngữ và chữ viết tắt

Topic Detection and Tracking	: Phát hiện và theo dõi sự kiện
First Story	: Bài viết đầu tiên về một sự kiện
First Story Detection	: Phát hiện bài viết đầu tiên
Nearest Neighbor Search	: tìm láng giềng gần nhất
Locality Sensitive Hashing	: thuật toán Locality Sensitive Hashing
Document	: một bài viết/điểm dữ liệu trong hệ thống
Tweet	: một bài đăng bởi bất kỳ người dùng nào trên Twitter
Merge Threshold	: Giá trị ngưỡng dùng khi xét hai docu- ment có đủ tương đồng để gom vào một cụm hay không

# Danh sách bảng

2.1	Độ tương đồng cosine giữa các document . . . . .	11
3.1	So sánh các thuật ngữ giữa SQL và MongoDB . . . . .	30
3.2	Các trường của collection News . . . . .	30
3.3	Các trường của collection HashCode . . . . .	31
3.4	Bảng User . . . . .	31
3.5	Bảng các thuộc tính . . . . .	32
3.6	Bảng các đối tượng hiển thị . . . . .	32
3.7	Bảng các thuộc tính . . . . .	32
3.8	Bảng các đối tượng hiển thị . . . . .	33
3.9	Bảng các thuộc tính . . . . .	33
3.10	Bảng các đối tượng hiển thị . . . . .	33
4.1	Thống kê dữ liệu gán nhãn . . . . .	37
4.2	Thống kê loại rác . . . . .	38
4.3	Danh sách từ khóa để thu thập dữ liệu . . . . .	38
4.4	Thông số cơ bản của tập train . . . . .	39
4.5	Thời gian train model . . . . .	39
4.6	Kết quả train model dựa trên một số độ đo . . . . .	40
4.7	Thông số cơ bản của tập train . . . . .	41
4.8	Thời gian train model . . . . .	41
4.9	Kết quả train model dựa trên một số độ đo . . . . .	42
4.10	Thông số cơ bản của tập train . . . . .	43
4.11	Thời gian train model . . . . .	43
4.12	Kết quả train model dựa trên một số độ đo . . . . .	44

# Danh sách hình vẽ

2.1	Cách xử lý một document mới trong thuật toán Nearest Neighbor Search	11
2.2	Cách xử lý một document mới theo thuật toán Boost Named Entity . .	14
2.3	Cách tính hash code cho một document trong một hash table . . . . .	17
3.1	Các thành phần chính của hệ thống . . . . .	24
3.2	Kiến trúc hệ thống crawler tin tức . . . . .	26
3.3	Kiến trúc hệ thống kết hợp Multilayer architecture kết hợp với mô hình MVC . . . . .	27
3.4	Kiến trúc giao diện hệ thống . . . . .	32
3.5	Giao diện danh sách tin đã phân lớp . . . . .	34
3.6	Giao diện thống kê biểu đồ thứ 1 và thứ 2 . . . . .	34
3.7	Giao diện thống kê biểu đồ thứ 3 . . . . .	35
3.8	Giao diện thống kê biểu đồ thứ 4 . . . . .	35
3.9	Giao diện bộ phân lớp tin tức . . . . .	35

# TÓM TẮT KHÓA LUẬN

Cùng với sự phát triển nhanh chóng của internet là sự tăng trưởng mạnh mẽ của ngành truyền thông báo chí. Cụ thể, tính đến ngày 31/12/2015, cả nước Việt Nam có 105 cơ quan báo điện tử, 207 trang thông tin điện tử tổng hợp của các cơ quan báo chí <sup>1</sup>, và cứ mỗi giờ có khoảng 2,118 bài được đăng trên các trang báo mạng Việt Nam <sup>2</sup>. Cùng với sự tăng trưởng lớn về thông tin là nhu cầu phân tích và xử lý các thông tin đó để phục vụ cho nhiều mục đích khác nhau, và ngày nay nhiều doanh nghiệp đã và đang xây dựng các hệ thống phân tích dữ liệu tin tức để phục vụ tốt hơn cho người dùng và biên tập viên.

Việc phân tích dữ liệu tin tức đòi hỏi hệ thống phải thu thập dữ liệu từ nhiều website tin tức khác nhau để có được một nguồn dữ liệu đa dạng, phong phú và đủ lớn. Tuy nhiên, dữ liệu thu thập từ các website có bản chất không phù hợp với mục đích của hệ thống phân tích có thể gây ra nhiễu và khiến cho kết quả phân tích, xử lý không chính xác. Do đó, việc sàng lọc dữ liệu thu thập được trước khi đưa vào phân tích và xử lý là cần thiết.

Hiểu được nhu cầu trên, chúng em thực hiện khóa luận này với mục tiêu xây dựng một hệ thống lọc "rác" cho dữ liệu tin tức từ các nguồn báo chính thống Việt Nam, cụ thể là lọc "rác" cho hệ thống "Phát hiện tin nóng".

Trong phạm vi của khóa luận, chúng em đã nghiên cứu một số thuật toán phân lớp: SVM, Naive Bayes, J48.

Sau quá trình thực hiện, đề tài khóa luận thu thập được các kết quả như sau:

- Thu thập bộ dữ liệu gồm các bài đăng trên các website tin tức Việt Nam.
- Đánh giá và so sánh các thuật toán: SVM, Naive Bayes, J48.

---

<sup>1</sup><http://mic.gov.vn/Pages/TinTuc/116095/Tinh-hinh-phat-trien-linh-vuc-bao-chi-va-phat-thanh-truyen-hinh-nam-2015.html>

<sup>2</sup>Theo thống kê từ dữ liệu thu thập bởi công ty VCCorp tính đến tháng 7/2017.

- 
- Xây dựng được hệ thống lọc rác cho hệ thống phát hiện tin nóng.

# Chương 1

## MỞ ĐẦU

### 1.1 Dẫn nhập

Trong thời đại bùng nổ về thông tin, báo chí điện tử là một trong những nguồn thông tin lớn và quan trọng cần được khai thác và phân tích một cách hiệu quả. Hệ thống phát hiện tin nóng hiện đang được triển khai và hoạt động tại VCCorp là một trong các hệ thống phân tích và xử lý dữ liệu tin tức, được phát triển nhằm mục đích xác định tin nóng từ các trang báo điện tử Việt Nam. Tuy nhiên, sự đa dạng và phong phú của nguồn tin dẫn đến việc bản chất của nhiều bài thu thập được không phù hợp với mục tiêu của hệ thống. Những bài đó, đối với hệ thống, được hiểu là "rác". Số lượng "rác" lớn sẽ gây nhiễu và làm cho việc phân tích và xử lý trở nên kém chính xác. Một cơ chế lọc rác hiệu quả sẽ giúp cải thiện độ chính xác cũng như giảm tải cho hệ thống từ việc phân tích và xử lý các dữ liệu không có giá trị sử dụng.

Bài toán đặt ra là làm thế nào để có thể lọc "rác" trong quá trình thu thập tin tức một cách chính xác. Với nhu cầu và điều kiện thuận lợi từ công ty VCCorp, khóa luận này hướng đến việc xây dựng một hệ thống có khả năng lọc "rác" để tăng hiệu quả cho hệ thống phát hiện tin nóng và giúp đánh giá độ đáng tin cậy của các nguồn tin.

### 1.2 Mục tiêu đề tài

- Tìm hiểu và đánh giá các thuật toán phân lớp cho việc lọc rác dữ liệu tin tức
- Xây dựng hệ thống lọc rác áp dụng các thuật toán phân lớp.



---

## 1.3 Nội dung thực hiện

- Tìm hiểu bài toán phân loại tin tức, tìm hiểu các phương pháp và các hướng tiếp cận
- Thử nghiệm đánh giá các phương pháp đã tìm hiểu:
  - Thu thập dữ liệu tin tức từ cơ sở dữ liệu của công ty VCCorp.
  - Tiến hành một số thống kê trên dữ liệu thu thập được.
  - Huấn luyện và so sánh các thuật toán phân lớp: Naive Bayes, SVM, J48.
- Xây dựng hệ thống:
  - Tìm hiểu về MongoDB, framework Struts 2, thư viện Apache Lucene, Weka, LibSVM.
  - Xây dựng kiến trúc hệ thống.
  - Thiết kế chức năng, giao diện hệ thống.
  - Cài đặt hệ thống.

## 1.4 Phạm vi đề tài

- Nguồn dữ liệu: các bài viết từ báo chính thống Việt Nam.
- Ngôn ngữ: tiếng Việt.
- Các thuật toán tìm hiểu: Naive Bayes, SVM, J48

## 1.5 Cấu trúc báo cáo

Luận văn được bố cục thành chương mục như sau:

- **Chương 1:** Mở đầu: Giới thiệu về đề tài.
- **Chương 2:** Bài toán lọc rác và các phương pháp tiếp cận phổ biến: Trình bày cơ sở lý thuyết, các khái niệm, phương pháp tiếp cận liên quan đến bài toán lọc rác.

- 
- **Chương 3:** Hiện thực hệ thống lọc rác: Trình bày về kiến trúc, cài đặt hệ thống phát hiện tin nóng.
  - **Chương 4:** Thực nghiệm và đánh giá: Trình bày về bộ dữ liệu thu thập được, đánh giá và so sánh các thuật toán.
  - **Mục Tài liệu tham khảo**
  - **Phụ lục. Giới thiệu về thư viện Apache Lucene**

## Chương 2

# BÀI TOÁN LỌC RÁC TIN TỨC VÀ CÁC PHƯƠNG PHÁP TIẾP CẬN PHỔ BIẾN

### 2.1 Mở đầu

Chương này sẽ giới thiệu bài toán lọc rác tin tức cho hệ thống phát hiện tin nóng. Trình bày cơ sở lý thuyết và phát biểu bài toán lọc rác tin tức. Cuối cùng trình bày một số phương pháp tiếp cận bài toán lọc rác tin tức và các kiến thức liên quan.

### 2.2 Giới thiệu bài toán

#### 2.2.1 Các khái niệm cơ bản

Để có thể xác định khái niệm rác, ta phải hiểu được khái niệm "tin nóng". Le [1] đã định nghĩa khái niệm "tin nóng" như sau:

- *Tin nóng (Hot news)*: những tin viết về một sự kiện mới xảy ra, có tính thời sự, có tầm ảnh hưởng rộng, thu hút được sự chú ý, quan tâm của cộng đồng.

Ngoài ra Gy ongyi và Garcia-Molina định nghĩa "đăng rác" như sau:

- *Đăng rác (Spamming)*: các hành động có chủ đích của con người nhằm thiên vị tính liên quan của một trang web nào đó, làm sai lệch giá trị của trang web.

Từ các khái niệm trên ta có định nghĩa "rác" cho bài toán như sau:

**Định nghĩa:** Rác là các tin không mang tính chất sự kiện, thời sự, và làm sai lệch kết quả phân tích và xử lý dữ liệu của hệ thống phân loại tin tức.

---

Từ định nghĩa trên ta có thể xác định được các loại tin sẽ được xem là rác:

- *Quảng cáo*: các bài quảng cáo, giới thiệu sản phẩm, các chương trình khuyến mãi, trúng thưởng.
- *Tuyển dụng*: các bài đăng tuyển dụng, giới thiệu việc làm của các tổ chức, doanh nghiệp.
- *Chia sẻ*: các bài chia sẻ mẹo vặt, thủ thuật, tâm sự, chuyện đời tư, giới thiệu ẩm thực, thời trang, hoặc các kiến thức chung.

### 2.2.2 Bài toán phân lớp văn bản

Bài toán phân lớp văn bản là bài toán có lịch sử lâu đời, một số ghi nhận cho thấy nó bắt đầu từ những năm 1800s, tuy nhiên tới nay vẫn chưa có một sự thống nhất nào về phương pháp tốt nhất cho bài toán phân lớp [2].

Theo Zechner [2], bài toán phân lớp văn bản gồm các thành phần chính cần quan tâm:

- Loại phân lớp: supervised hoặc unsupervised.
- Mục tiêu: đối tượng thành phần của văn bản mà ta muốn quan tâm.
- Kho từ vựng: kích thước và chất lượng của kho từ vựng ảnh hưởng lớn đến việc phân lớp.
- Features: đặc trưng của văn bản dùng cho việc phân lớp.
- Bộ phân lớp: thuật toán máy học dùng cho việc phân lớp.

### 2.2.3 Bài toán lọc rác tin tức

Bài toán lọc rác hay còn được biết đến như là bài toán phát hiện rác (Spam detection) là một dạng bài toán phân lớp văn bản nhị phân. Tức là chỉ có hai lớp: "rác" và "không rác". Đối với hệ thống phát hiện tin nóng cũng như các hệ thống phân tích và xử lý dữ liệu khác, việc phát hiện và lọc rác phải được diễn ra trước khi quá trình phân tích và xử lý dữ liệu bắt đầu để đảm bảo quá trình phân tích và xử lý dữ liệu chính xác và đáng tin cậy.

---

Mặc dù nguồn dữ liệu mà chúng ta quan tâm là tin tức từ các trang báo điện tử chính thống, số lượng nguồn tin, chủ đề tin và số lượng tin rất lớn dẫn đến việc chất lượng dữ liệu tin tức không được đảm bảo cũng như tính chất dữ liệu không được phù hợp với nhu cầu của hệ thống. Do đó việc lọc rác tin tức là cần thiết cho việc khai thác và sử dụng nguồn dữ liệu tin tức một cách hiệu quả.

#### 2.2.4 Phát biểu bài toán lọc rác tin tức cho hệ thống phát hiện tin nóng

Cho trước một bài báo  $d_i$ . Mục tiêu của bài toán là tìm ra được nhãn  $l_i$  của bài báo  $d_i$  và nhãn đó nhận một trong hai giá trị: "rác" và "không rác".

### 2.3 Các nghiên cứu liên quan

Vấn đề phát hiện và lọc rác là một vấn đề lâu đời và kinh điển đối với bài toán phân lớp văn bản. Do đó số lượng nghiên cứu xoay quanh vấn đề này cũng rất lớn và đa dạng. Phần lớn các nghiên cứu cho đến ngày nay tập trung vào việc phát hiện rác cho email và web.

Sahami và cộng sự [3] sử dụng các tiếp cận Bayesian vào vấn đề lọc rác cho email. Thực nghiệm cho thấy các bộ phân lớp đạt được hiệu suất cao hơn khi ta cân nhắc các tính năng đặc trưng theo domain và nội dung văn bản của email. Ngày nay thì các phương pháp phát hiện và lọc rác cho email đã khá hoàn thiện, và các phương pháp phát hiện và lọc rác Bayesian được áp dụng rộng rãi trong các email client và server.

Vấn đề phát hiện rác cho web thì khó khăn hơn vì độ lớn và tốc độ thay đổi nhanh chóng. Gyöngyi và cộng sự [4] đề xuất sử dụng thuật toán TrustRank để đo kiểm điểm tin cậy của đồ thị Web. Dựa trên điểm tin cậy, các trang web tốt sẽ được đánh giá cao hơn và những trang web xấu có thể được search engine bỏ qua.

### 2.4 Giới thiệu một số phương pháp trừu tượng hóa dữ liệu văn bản

Do máy tính không thể đọc hiểu và xử lý được dữ liệu thuần văn bản, ta cần có một phương pháp trừu tượng hóa dữ liệu văn bản thành các con số mà máy tính có thể hiểu được.

---

## Term Frequency - Inverse Document Frequency (TF-IDF)

Trong lĩnh vực thu thập thông tin, TF-IDF là một dữ liệu số dùng để thể hiện độ quan trọng của một từ trong một tập hợp hoặc một kho từ vựng [5]. Nó thường được dùng trong việc thu thập thông tin, text mining và user modeling. Giá trị của TF-IDF tăng theo tỉ lệ với số lần một từ xuất hiện trong một văn bản, nhưng thường bị giảm lại theo tần xuất của từ đó trong toàn kho từ vựng, vì một từ có thể chỉ đơn giản là nó phổ biến hơn các từ khác. Ngày nay, TF-IDF là một trong những phương pháp tính trọng số cho các từ phổ biến nhất; 83% các hệ thống khuyến nghị dựa trên văn bản trong lĩnh vực thư viện điện tử sử dụng TF-IDF [6].

TF-IDF gồm có hai thành phần chính Term Frequency (TF) và Inverse Document Frequency (IDF).

TF của từ  $t$  trong văn bản  $d$  được thể hiện dưới dạng  $tf(t, d)$ . Ta có nhiều cách tính TF, trong đó cách đơn giản nhất là đếm số lần một từ xuất hiện trong một văn bản. Nếu ta gọi số lần từ  $t$  xuất hiện trong văn bản  $d$  là  $f_{t,d}$  thì ta có  $tf(t, d) = f_{t,d}$

IDF là thước đo lượng thông tin một từ cung cấp, có nghĩa là liệu từ đó hiếm gặp hay xuất hiện xuyên suốt trong kho từ vựng. IDF được tính bằng công thức:

$$idf(t, D) = \log \frac{N}{1 + |\{d \in D : t \in d\}|} \quad (2.1)$$

Trong đó:

- $D$ : kho từ vựng.
- $N$ : số lượng văn bản trong kho từ vựng.
- $|\{d \in D : t \in d\}|$ : số lượng văn bản và có xuất hiện từ  $t$ .

## Word Vector

Word vector là một hình thức biểu diễn các từ trong một kho từ vựng dưới dạng các vector. Các từ thường xuất hiện cùng nhau trong các nhiều ngữ cảnh khác nhau thì sẽ được biểu diễn bằng các vector gần với nhau trong không gian vector [7]. Tập hợp các kỹ thuật để nhận vào input là một kho từ vựng và cho ra một không gian vector tương ứng được gọi là word2vec.

---

Word vector thường được sử dụng trong các công cụ tìm kiếm và dịch thuật do nó cung cấp thông tin về sự tương qua ngữ nghĩa giữa các từ và các ngữ cảnh cũng như giữa các từ với nhau.

## 2.5 Các phương pháp tiếp cận phổ biến

Phân lớp là quá trình xác định xem một đối tượng sẽ thuộc về lớp nào dựa trên việc quan sát các đối tượng khác mà lớp của chúng đã được xác định từ trước. Thông thường, các đối tượng cần phân lớp sẽ được phân tích thành các thuộc tính có thể đo đếm được. Một thuật toán dùng để phân lớp, hay còn được gọi là một bộ phân lớp, sẽ dựa trên các thuộc tính đó để ánh xạ các đối tượng input mới vào lớp của chúng. Đây là một trong những tác vụ chính của lĩnh vực khai thác dữ liệu.

Bài toán phân lớp bao gồm nhiều thuật toán khác nhau, trong phạm vi của khóa luận chúng ta sẽ chỉ quan tâm đến các thuật toán: Support vector machine, Naive Bayes, và J48 decision tree.

### 2.5.1 Thuật toán phân lớp Support Vector Machine (SVM)

#### 2.5.1.1 Ý tưởng

Support vector machine hay còn gọi là support vector network là một thuật toán phân lớp dành cho các bài toán phân lớp nhị phân. SVM thực hiện phân lớp bằng việc ánh xạ các vector lên một không gian nhiều chiều. Trên không gian này sẽ sinh ra một mặt phẳng quyết định tuyến tính phân tách hai lớp dữ liệu [8].

#### 2.5.1.2 Minh họa thuật toán

Giả sử ta có dữ liệu như hình vẽ. Đường tròn thể hiện ngưỡng khoảng cách để một document được xem là first story hay không, chọn ngưỡng giá trị 0.8. Ta có sẵn 4 document và 1 document mới vào hệ thống như sau:

$$\text{doc1} = (3,4,1,2)$$

$$\text{doc2} = (1,1,5,6)$$

$$\text{doc3} = (1,2,4,4)$$

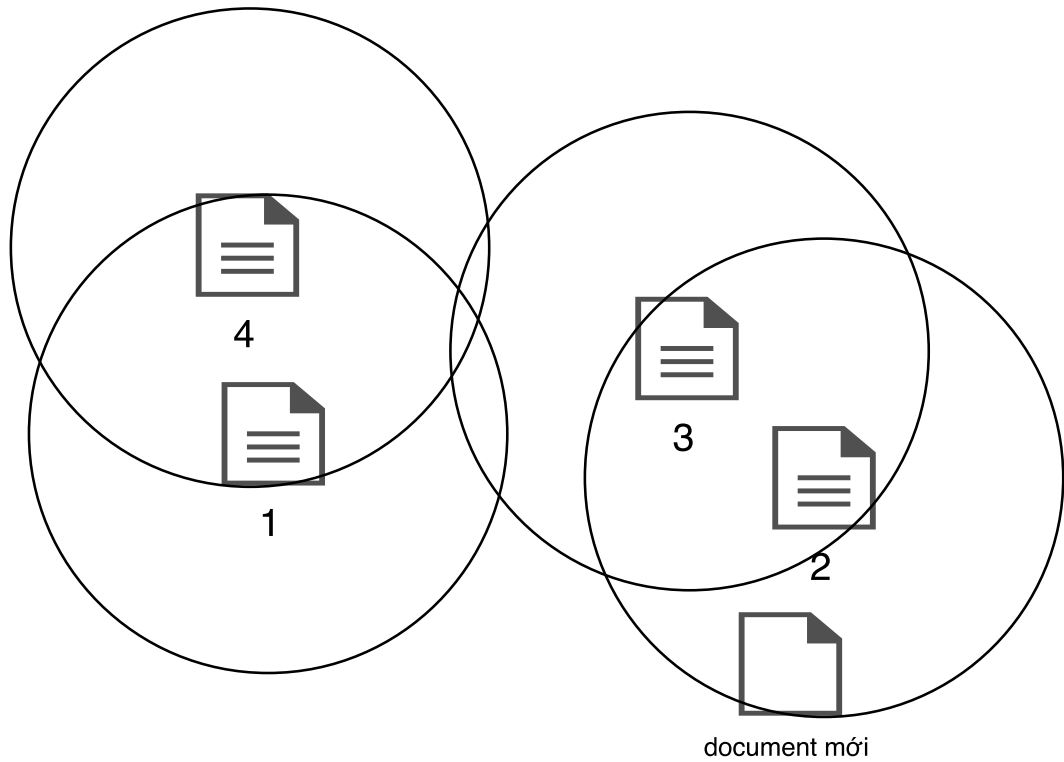
$$\text{doc4} = (3,5,1,1)$$

$$\text{newDoc} = (2,1,4,5)$$

	doc1	doc2	doc3	doc4	<b>newDoc</b>
doc1	1	0.55202	0.6903	0.973729	0.646058
doc2		1	0.973479	0.398962	0.984525
doc3			1	0.575396	0.969572
doc4				1	0.491473
newDoc					1

Bảng 2.1: Độ tương đồng cosine giữa các document

Ta có thể thấy document tương tự nhất của newDoc là doc2 (0.984525), lớn hơn ngưỡng cho trước (0.8), do đó newDoc được cho vào chung cụm với doc2 và không phải là một first story.



Hình 2.1: Cách xử lý một document mới trong thuật toán Nearest Neighbor Search



---

### 2.5.1.3 Mã giả

---

**Algorithm 1** Phát hiện tin nóng dựa trên k-Nearest neighbor

---

luồng bài viết từ Twitter, giá trị ngưỡng  $MergeThreshold$  các cụm bài viết **foreach** document  $d$  trong toàn bộ dữ liệu **do**  $S(d) \leftarrow \emptyset$  **foreach** term  $t$  trong document  $d$  **do** **foreach** document  $d'$  trong  $index[t]$  **do** cập nhật độ tương đồng  $similarity(d, d')$   $S(d) \leftarrow S(d) \cup d'$   $index[t] \leftarrow index[t] \cup d$  (thêm document  $d$  vào index của term  $t$ )  $similarity$  score của  $d$ :  $similarity_{max}(d) \leftarrow 0$  **foreach** document  $d'$  trong  $S(d)$  **do**  $similarity(d, d') > similarity_{max}(d)$   $similarity_{max}(d) \leftarrow similarity(d, d')$   $similarity_{max}(d) < MergeThreshold$   $d$  là một first story

---

Chú thích thuật toán:

- $MergeThreshold$ : ngưỡng để xét một document có phải là first story hay không
- $S(d)$ : tập document có ít nhất 1 term chung với  $d$
- $similarity(d, d')$ : độ tương đồng giữa document  $d$  và  $d'$ , có thể sử dụng các độ đo ở mục [2.4](#)
- $index(t)$ : danh sách các document có chứa term  $t$
- $dis_{min}(d)$ : khoảng cách giữa document  $d$  với document gần nhất

### 2.5.1.4 Ưu điểm, hạn chế

Ưu điểm:

- Đơn giản và dễ cài đặt.
- Có thể chọn nhiều độ đo khoảng cách khác nhau.
- Thích nghi tốt với nhiều loại dữ liệu.

Nhược điểm:

- Chi phí tính toán cao do phải lưu trữ và tính toán trên toàn bộ dữ liệu, không thể áp dụng cho luồng dữ liệu không liên tục.
- Độ chính xác giảm khi số chiều của dữ liệu tăng cao.

---

## 2.5.2 Thuật toán gom cụm có Boost trọng số cho Named Entity

### 2.5.2.1 Ý tưởng

Cách tiếp cận được đề xuất bởi Phuvipadawat là gom cụm các bài viết theo độ tương tự nội dung, với điểm nhấn là tăng giá trị tương đồng của các bài viết nếu chúng cùng đề cập đến một thực thể có tên (Named entity) nào đó [9]. Mỗi cụm thu được sẽ ứng với một sự kiện phát hiện được, với document cũ nhất làm đại diện cho cụm đó.

Theo Phuvipadawat, một đặc điểm của các bài viết trên Twitter là thường có nội dung khá ngắn (tối đa 140 kí tự, và ngắn hơn nữa sau khi tiền xử lý loại bỏ stop words). Việc sử dụng phương pháp TF-IDF truyền thống để tính độ tương đồng có thể không đạt được kết quả tốt do không có nhiều term để tìm ra sự tương đồng giữa các document. Vì thế tác giả đã đưa ra phương pháp tăng trọng số cho các danh từ riêng (Named Entity), qua đó tăng độ tương đồng giữa những bài viết cùng thảo luận về một sự vật, sự việc cụ thể nào đó.

Khi một document  $d$  mới được đưa vào hệ thống, ta so sánh độ tương đồng giữa  $d$  với tất cả cụm hiện có thông qua document đầu tiên trong cụm. Ta chọn ra cụm có độ tương đồng với  $d$  cao nhất, gán  $d$  vào cụm đó nếu độ tương đồng vượt ngưỡng định trước, ngược lại ta tạo cụm mới với  $d$  là document đầu tiên của cụm.

### 2.5.2.2 Minh họa thuật toán

Giả sử ta có một số document đã được gom nhóm sẵn thành 3 cụm như hình, ngưỡng  $\text{MergeThreshold} = 0.7$ , mỗi cụm có một  $\text{firstDoc}$  làm đại diện. Đường tròn thể hiện ngưỡng khoảng cách để một document được xem là first story hay không.

Khi một document mới ( $\text{newDoc}$ ) vào hệ thống:

- Bước 1: So sánh  $\text{newDoc}$  với từng  $\text{firstDoc}$  của từng cụm:


$$\text{similarity}(\text{newDoc}, g1.\text{firstDoc}) = 0.6$$

$$\text{similarity}(\text{newDoc}, g2.\text{firstDoc}) = 0.5$$

$$\text{similarity}(\text{newDoc}, g3.\text{firstDoc}) = 0.35$$

- Bước 2: Tìm cụm có  $\text{firstDoc}$  tương tự với  $\text{newDoc}$  nhất: Chọn được cụm  $g1$

- Bước 3:  $\text{similarity}(\text{newDoc}, g1.\text{firstDoc}) = 0.6$  nhỏ hơn MergeThreshold: Tạo cụm g4 với  $g4.\text{firstDoc} = \text{newDoc}$ .



Hình 2.2: Cách xử lý một document mới theo thuật toán Boost Named Entity

### 2.5.2.3 Mã giả

---

**Algorithm 2** Phát hiện tin nóng sử dụng gom cụm theo nội dung, boost Named Entity

---

luồng bài viết từ Twitter, giá trị ngưỡng MergeThreshold các cụm bài viết ứng với mỗi story phát hiện được, có thứ tự xếp hạng giữa các cụm

**foreach** document  $d$  trong toàn bộ dữ liệu **do**  $MaxScore_d \leftarrow 0$   $IDMaxScore_d \leftarrow \emptyset$

**foreach** cụm  $g$  trong tập hợp cụm  $G$  **do** tính  $Score_d[g] \leftarrow \text{similarity}(d, g.\text{firstDoc})$   $MaxScore_d < Score_d[g]$   $MaxScore_d \leftarrow Score_d[g]$   $IDMaxScore_d \leftarrow g.\text{groupID}$   $MaxScore_d > \text{MergeThreshold}$   $g_{\text{new}}.\text{firstDoc} \leftarrow d$

---

Chú thích thuật toán:

1.  $MaxScore_d$ : chứa độ tương đồng lớn nhất giữa document  $d$  và các cụm đã có

- 
- $IDMaxScore_d$ : ID của cụm tương đồng nhất với document d
  - $Score_d[g]$ : độ tương đồng giữa document d với cụm g
  - $MergeThreshold$ : ngưỡng để xét một document có thuộc về cụm/có là first story hay không

Độ tương đồng giữa 2 document được tính bằng các công thức sau:

$$similarity(d_1, d_2) = \sum_{t \in d_1, t \in g.topTerms} [tf(t, d_2) \times idf(t) \times boost(t)] \quad (2.2)$$

$$tf(t, d) = \frac{count(t \in d)}{size(d)} \quad (2.3)$$

$$idf(t) = 1 + \log \frac{N}{count(m \text{ has } t)} \quad (2.4)$$

Các kí hiệu:

- $similarity(d_1, d_2)$ : độ tương đồng giữa document  $d_1$  và document  $d_2$
- $boost(t)$ : giá trị boost cho term t, nếu t là một danh từ riêng (Named Entity) thì  $boost(t) > 1$ , ngược lại  $boost(t) = 1$
- $tf(t, d)$ : tần suất xuất hiện (theo phần trăm) của term t trong document d
- $count(t \in d)$ : tần suất term t xuất hiện trong document d
- $size(d)$ : số lượng term của document d
- $idf(t)$ : giá trị inverse document frequency của term t
- $N$ : tổng số document trong hệ thống
- $count(m \text{ has } t)$ : số document có chứa term t

#### 2.5.2.4 Ưu điểm, hạn chế

Ưu điểm:

- Dễ gom nhóm được các sự kiện bàn về cùng thực thể nào đó.

Nhược điểm:

- 
- Chất lượng kết quả gom cụm phụ thuộc một phần vào việc phát hiện được thực thể có tên.

### 2.5.3 Thuật toán Locality Sensitive Hashing

#### 2.5.3.1 Ý tưởng

Thuật toán tìm kiếm láng giềng gần nhất tốn rất nhiều chi phí khi lượng dữ liệu càng lớn. Thay vào đó, ta có thể giải bài toán tìm *xấp xỉ* láng giềng gần nhất. Một thuật toán để giải quyết bài toán này là *Locality Sensitive Hashing (LSH)* được đề xuất bởi Piotr Indyk và cộng sự [10].

LSH hoạt động bằng cách chia không gian biểu diễn dữ liệu thành nhiều vùng riêng biệt bằng một tập các siêu phẳng ngẫu nhiên. Ta có thể xem mỗi cách chia không gian này ứng với một hash table, và số bit của hash code bằng với số lượng siêu phẳng đã dùng để chia không gian. Mỗi khi một document mới vào hệ thống, ta tính hash code của nó. Khi cần tìm láng giềng cho một document, ta chỉ cần so sánh nó với các document thuộc chung vùng không gian (ứng với một bucket trong hash table), nhờ đó giảm đáng kể chi phí tính toán.

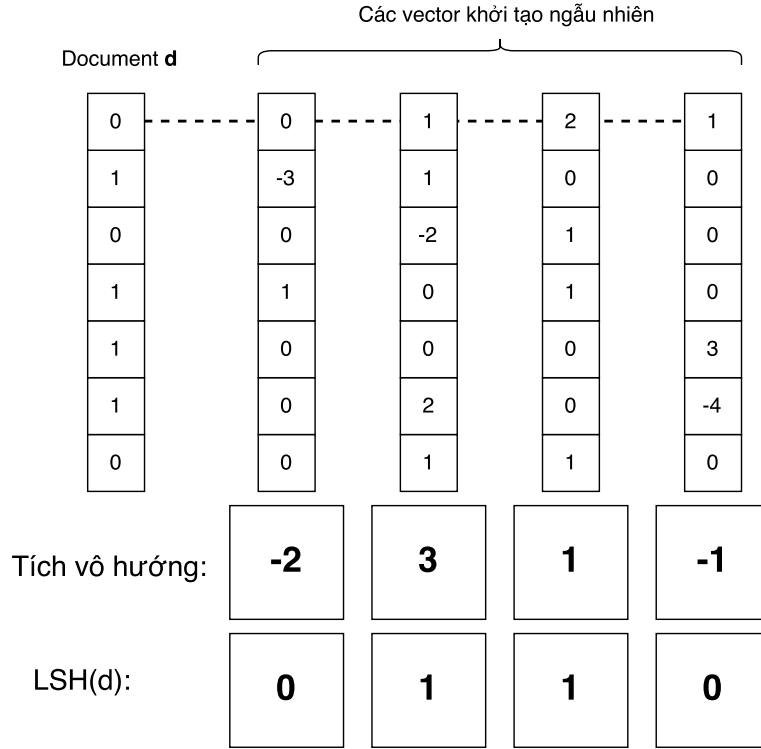
Vì các siêu phẳng được chọn một cách ngẫu nhiên, nên đôi khi các document dù gần nhau vẫn có thể bị phân vào vùng khác nhau. Do đó ta thường dùng cùng lúc nhiều hash table để tăng thêm khả năng tìm được láng giềng gần nhất.

#### 2.5.3.2 Minh họa cách tính hash code cho LSH

Giả sử ta có không gian biểu diễn document gồm 7 từ/term khác nhau (8 chiều). Xét một document  $d$  biểu diễn dưới dạng vector  $d = (0, 1, 0, 1, 1, 1, 0)$ , và ta chọn sử dụng hash code có 4 bit (dùng 4 siêu phẳng để chia không gian dữ liệu).

Mỗi hash table được khởi tạo bằng cách: tạo 4 vector ngẫu nhiên ứng với 4 siêu phẳng, số chiều bằng 7, ứng với số chiều của vector  $d$ .

Cách tính hash code của document  $d$  trong một hash table như sau: lần lượt tính tích vô hướng của vector  $d$  với từng vector của các siêu phẳng, nếu tích dương thì bit đó có giá trị 1, nếu tích âm thì có giá trị 0.



Hình 2.3: Cách tính hash code cho một document trong một hash table

### 2.5.3.3 Mã giả

---

**Algorithm 3** Phát hiện tin nóng sử dụng Locality Sensitive Hashing

---

luồng bài viết từ Twitter, giá trị ngưỡng  $t$  những cụm bài viết

Khởi tạo  $L$  hash tables    **foreach** document  $d$  mới **do**    **foreach** hash table  $l$  trong  $L$  **do**

Tính hash code cho document  $d$ :  $LSH_l(d)$     Thêm tất cả các documents  $d'$  có  $LSH_l(d') = LSH_l(d)$  vào tập  $S$      $dis_{min}(d) = 1$

**foreach** document  $d'$  trong  $S$  **do**  $distance(d, d') < dis_{min}(d)$      $dis_{min}(d) = distance(d, d')$      $dis_{min}(d) \geq t$  tạo cụm mới chứa  $d$  thêm  $d$  vào cụm chứa hàng xóm gần nhất của  $d$

---

Chú thích thuật toán:

•  $t$ : ngưỡng để xét một document có phải là first story hay không

•  $LSH_l(d)$ : hash code của document  $d$  trong hash table thứ  $l$

•  $dis_{min}(d)$ : khoảng cách giữa document  $d$  với document gần nhất

Ưu điểm:

- Chi phí tính toán thấp do không cần so sánh toàn bộ các document với nhau.
- Độ chính xác tương đối tốt

Nhược điểm:

- Cần tìm chọn các thông số như: số lượng hash table, số lượng bit trong hash code,... tốt để cho kết quả chính xác.
- Có thể không tìm được document thật sự tương đồng nhất, trong trường hợp các điểm không được chia vào cùng vùng trong không gian do cách thiết lập của các siêu phẳng trong hash tables.

#### 2.5.3.4 LSH cải tiến

Dựa vào dữ liệu thực nghiệm của mình, Sasa Petrovic và cộng sự [11] đưa ra nhận định rằng việc áp dụng LSH thuần túy vào bài toán FSD cho ra kết quả chưa tốt. Trong trường hợp điểm dữ liệu cách xa tất cả điểm còn lại, LSH không tìm được láng giềng gần nhất, do không có điểm nào khác rơi vào cùng bucket trong các hash table, dẫn đến không có điểm dữ liệu khác để so sánh.

Để giải quyết vấn đề này, Petrovic đưa ra phương án: mỗi khi tìm ra document  $d$  có  $dis_{min}(d)$  lớn hơn ngưỡng, ta áp dụng thuật toán tìm láng giềng gần nhất giữa document  $d$  và khoảng 1000 tới 3000 document có thời gian gần đây nhất trong hệ thống, cập nhật giá trị  $dis_{min}(d)$  và xét xem nó vẫn vượt ngưỡng hay không, nếu có thì ta kết luận  $d$  là một first story, ngược lại ta cho  $d$  vào cụm của láng giềng gần nó nhất.

---

**Algorithm 4** Phát hiện tin nóng sử dụng Locality Sensitive Hashing kết hợp với Nearest Neighbor Search

---

luồng bài viết từ Twitter, giá trị ngưỡng  $t$  những cụm bài viết

Khởi tạo  $L$  hash tables

**foreach** document  $d$  mới **do**

**foreach** hash table  $l$  trong  $L$  **do**

Tính hash code cho document  $d$ :  $LSH_l(d)$

Thêm tất cả các documents  $d'$  có  $LSH_l(d') = LSH_l(d)$  vào tập  $S$

$dis_{min}(d) = 1$

**foreach** document  $d'$  trong  $S$  **do**

$distance(d, d') < dis_{min}(d)$

$dis_{min}(d) = distance(d, d')$

$dis_{min}(d) \geq t$

Tính khoảng cách giữa  $d$  với một lượng (1000-3000) documents mới nhất trong bộ dữ liệu, cập nhật  $dis_{min}(d)$  nếu có thay đổi.  $dis_{min}(d) \geq t$  tạo cụm mới chứa  $d$  thêm  $d$  vào cụm chứa hàng xóm gần nhất của  $d$

---

---

## 2.6 Giới thiệu một số độ đo đánh giá phân lớp

Đánh giá chất lượng của kết quả gom cụm là nhiệm vụ khó khăn và phức tạp, do bản chất không hoàn toàn rõ ràng về định nghĩa của một "cụm". Theo tác giả Pang-Ning Tan và cộng sự [12], có 3 loại phương pháp để đánh giá chất lượng cụm:

- Đánh giá ngoại, có giám sát (External evaluation): Các độ đo có sử dụng thông tin bên ngoài như nhãn lớp của dữ liệu để so sánh với kết quả gom cụm. VD: Purity, Rand measure,...
- Đánh giá nội, không giám sát (Internal evaluation): Chỉ dựa vào các thông tin, thuộc tính có sẵn trong cụm để đánh giá. VD: Silhouette index, Dunn index, Davies–Bouldin index...
- Đánh giá tương đối (Relative evaluation): So sánh kết quả giữa các phương pháp gom cụm hoặc giữa các cụm, có thể dùng độ đo ngoại lẫn nội.

### 2.6.1 Khoảng cách cục bộ và toàn cục (Intra-cluster và Inter-cluster distance)

Hai độ đo này thuộc loại đánh giá nội, chỉ dựa vào chính dữ liệu được gom cụm để tính giá trị của chúng. Khoảng cách cục bộ của một cụm thể hiện mức độ các điểm dữ liệu trong một cụm tương đồng với nhau thế nào. Dưới đây là 3 cách để tính khoảng cách cục bộ:

- Dùng khoảng cách giữa 2 điểm xa nhau nhất trong cụm:

$$intraclusterDistance(C_i) = \max_{x,y \in C_i} distance(x, y)$$

- Dùng trung bình khoảng cách giữa tất cả cặp điểm trong cụm:

$$intraclusterDistance(C_i) = \frac{1}{size(C_i) * [size(C_i)-1]} \sum_{x,y \in C_i, x \neq y} distance(x, y)$$

- Dùng trung bình khoảng cách giữa từng điểm với tâm cụm:

$$intraclusterDistance(C_i) = \frac{\sum_{x \in C_i} distance(x, \mu)}{size(C_i)}, \mu = \frac{\sum_{x \in C_i} x}{size(C_i)}$$



---

Khoảng cách toàn cục là giá trị cho thấy mức độ rời rạc giữa tất cả các cụm với nhau, được tính bằng trung bình khoảng cách giữa các cụm:

$$interclusterDistance = \frac{1}{size(C) * [size(C) - 1]} \sum_{C_i, C_j \in C} distance(C_i, C_j) \quad (2.5)$$

Trong đó, khoảng cách giữa 2 cụm  $distance(C_i, C_j)$  cũng có thể được xác định bằng nhiều cách như:

- Dùng khoảng cách giữa 2 điểm xa nhau nhất trong 2 cụm:

$$distance(C_i, C_j) = \max_{x \in C_i, y \in C_j} distance(x, y)$$

- Dùng trung bình khoảng cách giữa tất cả cặp điểm trong 2 cụm:

$$distance(C_i, C_j) = \frac{1}{size(C_i) + size(C_j)} \sum_{x \in C_i, y \in C_j} distance(x, y)$$

- Dùng khoảng cách giữa 2 tâm cụm:

$$distance(C_i, C_j) = distance(\mu_{C_i}, \mu_{C_j}), \text{ với } \mu_{C_i} = \frac{\sum_{x \in C_i} x}{size(C_i)}$$

Chú thích kí hiệu:

- $C_i$ : cụm dữ liệu thứ  $i$
- $x, y$ : 2 điểm dữ liệu bất kì
- $distance(x, y)$ : khoảng cách giữa 2 điểm dữ liệu, dùng các khoảng cách ở mục 2.4
- $size(C_i)$ : số lượng điểm dữ liệu được gom vào cụm  $i$

### 2.6.2 Độ đo Dunn index

Dunn index được đề xuất bởi J. C. Dunn [13], độ đo này thể hiện mức độ gắn kết của từng cụm lẫn độ rời rạc giữa các cụm. Giá trị Dunn index được tính theo công thức sau:

$$DI = \frac{\min_{1 \leq i \leq j \leq n} distance(C_i, C_j)}{\max_{1 \leq k \leq n} intraclusterDistance(k)} \quad (2.6)$$

Với  $n$  là tổng số cụm thu được, và  $intraclusterDistance$  được tính theo một trong những cách ở mục 2.6.1.

Giá trị Dunn index càng cao thì các cụm càng tách biệt nhau và mỗi cụm thì có những điểm dữ liệu gom sát với nhau. Tuy vậy, mẫu số trong công thức (2.6) lấy khoảng

---

cách cục bộ của cụm rời rạc nhất chứ không lấy trung bình tất cả cụm, nên giá trị Dunn index là trường hợp xấu nhất chứ không phải trường hợp trung bình.

### 2.6.3 Hệ số Silhouette (Silhouette coefficient)

Silhouette là một độ đo xem xét các đối tượng trong dữ liệu có được gán vào cụm hợp lý hay không, thông qua việc so sánh cả độ gắn kết của từng cụm và độ rời rạc giữa các cụm. Với mỗi điểm dữ liệu, giá trị silhouette coefficient nằm trong khoảng từ -1 đến 1, giá trị này cao khi điểm dữ liệu tương đồng với cụm của nó và ít tương đồng với cụm khác, và ngược lại.

Cách tính hệ số Silhouette cho một điểm dữ liệu  $i$  như sau:

1. Tính khoảng cách trung bình giữa  $i$  với các điểm trong cùng cụm với  $i$ . Gọi giá trị này là  $a_i$ .
2. Với mỗi cụm  $g$  không chứa  $i$ , tính khoảng cách của  $i$  đến cụm  $g$  bằng trung bình khoảng cách giữa  $i$  với từng điểm trong cụm  $g$ , chọn cụm có khoảng cách đến  $i$  *nhỏ nhất*. Gọi giá trị này là  $b_i$ .
3. Tính hệ số Silhouette theo công thức sau:

$$s(i) = \frac{b_i - a_i}{\max\{a_i, b_i\}} \quad (2.7)$$

Ở đây  $a_i$  đại diện cho độ bất phù hợp của điểm  $i$  với cụm của nó, và  $b_i$  đại diện cho độ tương đồng giữa điểm  $i$  với cụm gần nhất không chứa  $i$ . Vì vậy khi  $a_i$  nhỏ,  $b_i$  lớn, giá trị hệ số silhouette tiến tới 1, nghĩa là điểm dữ liệu  $i$  rất phù hợp với cụm của nó và không phù hợp với cụm khác. Trong trường hợp ngược lại, giá trị silhouette tiến tới -1.

Giá trị hệ số Silhouette cho một kết quả phân cụm được tính bằng trung bình hệ số Silhouette của tất cả điểm dữ liệu.

### 2.6.4 Độ đo Purity

Đây là một độ đo đánh giá ngoại. Dựa trên nhãn lớp của dữ liệu, purity là độ đo về tính thuần khiết/độ đồng nhất của các cụm. Giá trị này tính bằng cách lấy tần số của

---

lớp chiếm số lượng nhiều nhất trong cụm (tính theo phần trăm kích cỡ cụm). Purity càng cao khi cụm chứa càng nhiều điểm dữ liệu thuộc cùng một nhãn lớp.

Giá trị purity của một cụm  $C_i$  được tính bằng công thức:

$$purity(C_i) = \max_j \left( \frac{m_{ij}}{m_i} \right) \quad (2.8)$$

Trong đó:

- $m_i$ : số điểm dữ liệu thuộc cụm  $i$
- $m_{ij}$ : số điểm dữ liệu thuộc lớp  $j$  và nằm trong cụm  $i$

Giá trị purity của tất cả cụm được tính như sau:

$$purity = \sum_{i=1}^K \frac{m_i}{m} purity(C_i) \quad (2.9)$$

Trong đó:

- $K$ : tổng số cụm
- $m$ : tổng số điểm dữ liệu

## 2.7 Xếp hạng cụm

Một yêu cầu của bài toán phát hiện tin nóng là các chuỗi tin (ứng với các cụm) phải được sắp xếp theo mức độ nóng giảm dần. Hầu hết các phương pháp đã khảo sát trong khóa luận này chỉ tập trung vào việc gom cụm và cải thiện chất lượng cụm, mà không đề cập đến việc sắp xếp cụm theo thứ tự nào đó.

Tác giả Phuvipadawat đưa ra một số công thức để tính điểm lượng giá độ nóng của chuỗi tin, và các chuỗi tin được sắp xếp theo giá trị điểm giảm dần [9].

Điểm này cân nhắc tầm ảnh hưởng của những người viết bài trong cụm, cũng như mức độ lan tỏa của chính các bài viết trong cụm. Giá trị điểm cũng được cập nhật thường xuyên và sẽ giảm dần theo thời gian nếu không có những bài viết mới làm tăng điểm cho nó. So với công thức của Phuvipadawat, công thức 2.12 bổ sung thêm yếu tố

---

lượng favorite của cụm, do đây cũng là một thành phần ghi nhận phản ứng từ người dùng Twitter.

Giá trị điểm xếp hạng của một cụm  $C_i$  được cho bằng công thức sau:

$$Score(C_i) = \frac{1}{Z} \sum_{j=1}^k \frac{S_i}{\log_2(\Delta_j + 2)} \quad (2.10)$$

Với  $S_i$  tính bằng:

$$S_i = w_1 \sum_{u_i \in C_i} FollowerCount(u_i) + w_2 TotalRetweetCount(C_i) + w_3 TotalFavoriteCount(C_i) \quad (2.11)$$

Trong đó:

- $\frac{1}{Z}$ : giá trị để chuẩn hóa điểm cụm,  $Z$  là tổng điểm của các cụm khi chưa chuẩn hóa
- $k$ : số lượng document trong cụm
- $\Delta_j$ : chênh lệch thời gian giữa thời điểm hiện tại với thời gian bài viết  $j$  được đăng
- $w_1, w_2$ : trọng số cho hai vế của biểu thức
- $u_i$ : người dùng thứ  $i$
- $FollowerCount(u_i)$ : số người follow người dùng  $u_i$  trên Twitter
- $TotalRetweetCount(g_i)$ : tổng số retweet của các bài đăng trong cụm  $c_i$

## 2.8 Kết chương

Chương này đã phát biểu bài toán phát hiện tin nóng và đưa ra 4 thuật toán tiếp cận theo hướng gom cụm. Đồng thời trình bày về các độ đo tương đồng, độ đo đánh giá chất lượng cụm và cách xếp hạng cụm. Chương tiếp theo sẽ trình bày về việc xây dựng hệ thống phát hiện tin nóng.

## Chương 3


# HIỆN THỰC HỆ THỐNG PHÁT HIỆN TIN NÓNG

### 3.1 Mở đầu

Chương này sẽ trình bày về thiết kế, chi tiết cài đặt, các thư viện và framework được sử dụng để xây dựng hệ thống lọc rác tin tức.

### 3.2 Mô hình hệ thống

Dưới đây là mô hình của các thành phần chính hệ thống:



Hình 3.1: Các thành phần chính của hệ thống

Hệ thống chủ yếu phục vụ cho biên tập viên. Biên tập viên sử dụng hệ thống thông qua giao diện Spam Filtering để sử dụng chức năng phân lớp tin tức hoặc xem các số liệu thống kê về tin tức đã phân lớp lưu trong cơ sở dữ liệu.

---

### 3.3 Phân hệ thu thập dữ liệu (Data Streaming)

Module này sử dụng hệ thống Crawler để lấy các bài đăng từ nhiều nguồn tin tức lưu trữ ở cơ sở dữ liệu MySQL và đưa qua cơ sở dữ liệu MongoDB, hệ thống sẽ thực hiện các chức năng:

- Connect vào cơ sở dữ liệu mySQL để lấy các bài bài báo.
- Xóa các bài viết trùng.
- Lưu trữ xuống cơ sở dữ liệu MongoDB

### 3.4 Phân hệ tiền xử lý dữ liệu (Data Preprocessor)

Module tiền xử lý có nhiệm vụ chính gồm loại bỏ URL, thực hiện tách từ, loại bỏ stopwords và biểu diễn dữ liệu thành vector trọng số tf-idf. Trước khi chạy thuật toán phân loại, dữ liệu được lấy ra từ MongoDB và tiền xử lý phần nội dung của bài báo bằng các bước sau:

1. Loại bỏ URL bằng regular expression.
2. Tách từ sử dụng thư viện TPSegmenter. Bước này dùng để biểu diễn các từ ghép trong tiếng Việt bằng cách thêm gạch nối giữa các tiếng của từ.  
Ví dụ: *"Vụ tai nạn 13 người chết: Đã giám định mẫu máu tài xế xe tải"* qua bộ tách từ sẽ thành *"Vụ tai \_ nạn 13 người chết : Đã giám \_ định mẫu máu tài \_ xế xe \_ tải"*.
3. Loại bỏ các từ trong danh sách gồm 813 stopwords.
4. Tính và biểu diễn dữ liệu thành vector tf-idf và metadata.

### 3.5 Phân hệ phân loại tin tức

Sử dụng model đã train trước đó để phân loại tin tức. Model sử dụng thuật toán SVM đã trình bày ở chương 2 làm thuật toán chính để phân loại tin tức. Hiện tại hệ thống có 2 nhãn đã được định nghĩa trước đó:

- 
- Không rác
  - Rác

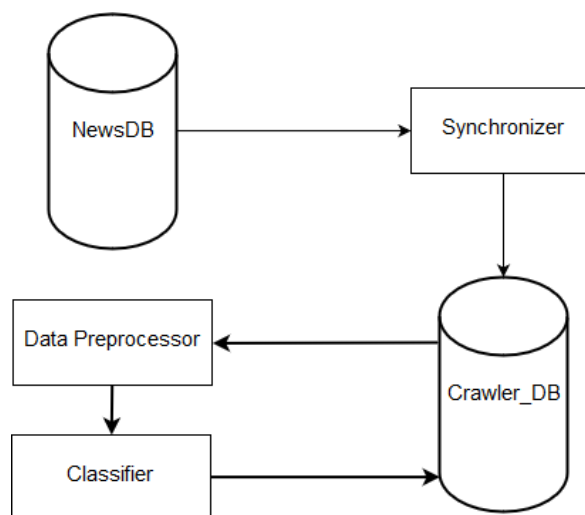
Sau khi đã phân loại, hệ thống sẽ lưu nhãn đã gán cho tin tức xuống cơ sở dữ liệu MongoDB.

### 3.6 Phân hệ phân loại loại rác

Hệ thống sẽ lấy những tin được gán nhãn "Rác" ở bước phân loại tin tức ở trên để phân loại loại rác cho tin đó. Hiện tại có 3 loại rác đã được định nghĩa trước:


- Quảng cáo
- Tuyển dụng
- Chia sẻ

### 3.7 Thiết kế hệ thống



Hình 3.2: Kiến trúc hệ thống crawler tin tức

Hệ thống Crawler được xây dựng độc lập bao gồm phân hệ thu thập dữ liệu, phân hệ tiền xử lý và phân hệ phân lớp để chạy ngầm nhằm thu thập và phân loại thông tin



Hình 3.3: Kiến trúc hệ thống kết hợp Multilayer architecture kết hợp với mô hình MVC

Hệ thống xây dựng theo kiến trúc 3 tầng gồm: Presentation Layer, Business Logic Layer và Data Access Layer. Trong đó, Presentation Layer áp dụng mô hình Model - View - Controller (MVC). Cụ thể:

- Presentation Layer: Có trách nhiệm hiển thị thông tin, tương tác với người dùng hệ thống. Gồm 2 thành phần:
  - Controller: Điều khiển các luồng của hệ thống web, nhận các tín hiệu từ người dùng và xử lý tương ứng.
  - View: Có nhiệm vụ hiển thị các giao diện hệ thống cho người dùng, hệ thống sử dụng React để gọi api trả về dữ liệu cho giao diện người dùng.
- Model: Đối tượng chứa dữ liệu để xử lý và hiển thị.
- Business Layer: Chứa các nghiệp vụ của hệ thống. Bao gồm các bước xử lý dữ liệu, thuật toán gom cụm, các tác vụ thống kê,...



- 
- Data Access Layer: Có nhiệm vụ giao tiếp với các hệ cơ sở dữ liệu.

## 3.8 Cài đặt hệ thống

Hệ thống ứng dụng được xây dựng trên nền tảng Java EE với các thành phần sau:

- Ngôn ngữ: Java, HTML, CSS, JavaScript, React.
- Hệ cơ sở dữ liệu: MongoDB và MySQL.
- Thư viện, framework: Apache Struts 2, Apache Lucene, TPEgmenter, Weka
- Server: Apache Tomcat

### 3.8.1 Các package

Source code chương trình được tổ chức thành các package như sau:

Hệ thống crawler:

- vn.vccorp.crawler.bo: Chứa các business object của hệ thống
- vn.vccorp.crawler.config: Các file config cho hệ thống
- vn.vccorp.crawler.constant: Các file constant của hệ thống
- vn.vccorp.crawler.dao: Data Access Object, thực hiện các tác vụ đọc, ghi database
- vn.vccorp.crawler.dbconnection: Cung cấp kết nối đến database
- vn.vccorp.crawler.dto: Data Transfer Object, các đối tượng để vận chuyển dữ liệu từ database
- vn.vccorp.crawler.main: Các lớp bao đóng để tạo thread chạy song song các tác vụ
- vn.vccorp.crawler.thread: Các lớp bao đóng để tạo thread chạy song song các tác vụ
- vn.vccorp.crawler.util: Các công cụ hỗ trợ trong hệ thống

Hệ thống HotNewsDetector:

- 
- vn.vccorp.hotnewsdetector.action.general: lớp ảo chứa các phương thức của action.
  - vn.vccorp.hotnewsdetector.action.news: chứa các action cho tin tức
  - vn.vccorp.hotnewsdetector.action.twitter: chứa các action cho twitter
  - vn.vccorp.hotnewsdetector.bo: Chứa các business object của hệ thống
  - vn.vccorp.hotnewsdetector.config: Các file config cho hệ thống
  - vn.vccorp.hotnewsdetector.constant: Các file constant của hệ thống
  - vn.vccorp.hotnewsdetector.context: chứa các action context của hệ thống
  - vn.vccorp.hotnewsdetector.crawler.news: Dùng để lấy dữ liệu từ trang web tin tức
  - vn.vccorp.hotnewsdetector.dao: Data Access Object, thực hiện các tác vụ đọc, ghi database
  - vn.vccorp.hotnewsdetector.dbconnection: Cung cấp kết nối đến database
  - vn.vccorp.hotnewsdetector.dto: Data Transfer Object, các đối tượng để vận chuyển dữ liệu từ database
  - vn.vccorp.hotnewsdetector.exception: Quản lý lỗi và đưa ra thông báo của hệ thống
  - vn.vccorp.hotnewsdetector.thread
  - vn.vccorp.hotnewsdetector.utils

### 3.8.2 Cơ sở dữ liệu MongoDB

Hệ thống sử dụng MongoDB để lưu trữ dữ liệu tin tức và quản lý kết quả phân lớp. Đây là một hệ cơ sở dữ liệu NoSQL, cung cấp khả năng mở rộng, sao lưu, phân mảnh dữ liệu tốt, và có thể thay đổi cấu trúc dữ liệu một cách linh hoạt.

Dưới đây là bảng so sánh một số thuật ngữ cơ bản giữa các cơ sở dữ liệu SQL truyền thống và MongoDB:

---

Thuật ngữ SQL	Thuật ngữ MongoDB
database	database
table	collection
row	document hoặc BSON document
column	field
index	index
table joins	\$lookup, embedded documents

Bảng 3.1: So sánh các thuật ngữ giữa SQL và MongoDB

### 3.8.2.1 Collection News

Collection này chứa thông tin về các tin lấy từ cơ sở dữ liệu MySQL, cũng là nơi lưu trữ tất cả thông tin về tweet trong hệ thống. Khi dữ liệu được stream từ MySQL về, mỗi tin chỉ có 12 trường, các trường khác sẽ được thêm vào trong quá trình hệ thống xử lý.

Thuộc tính	Loại	Ý nghĩa
_id	ObjectID	ID trong MongoDB của document
Id	Int	ID của tin tức lấy về
Title	String	Title của tin tức
Content	String	Nội dung của tin tức
Source	String	Nguồn trang báo điện tử của tin tức
CreateTime	Date	Thời gian đăng của tin
GetTime	Date	Thời gian tin tức được thu thập vào cơ sở dữ liệu MySQL
CollectDate	Date	Thời gian tweet được thu thập vào cơ sở dữ liệu MongoDB
Author	String	Người viết bài báo(nếu có)
Category	Integer	Chủ đề của bài báo
SpamLabel	String	Nhân đã gán cho tin tức
SpamCategory	String	Nhân đã gán cho loại tin rác
SpamLabelFeedback	Integer	Feedback của nhân đã gán cho tin tức đó

Bảng 3.2: Các trường của collection News

### 3.8.2.2 Collection HashCode

Collection cluster chứa các hash code cho bài báo để kiểm tra trùng cho tin tức đó.

---

Thuộc tính	Loại	Ý nghĩa
<code>_id</code>	ObjectID	ID trong MongoDB của cụm
HashCode	String	Hash code của tin tức

Bảng 3.3: Các trường của collection HashCode

«««< HEAD

### 3.8.3 Cơ sở dữ liệu MySQL

MySQL được dùng để lưu trữ các dữ liệu khác của hệ thống như dữ liệu người dùng, các từ khóa dùng cho việc streaming dữ liệu Twitter,...

#### 3.8.3.1 Bảng User

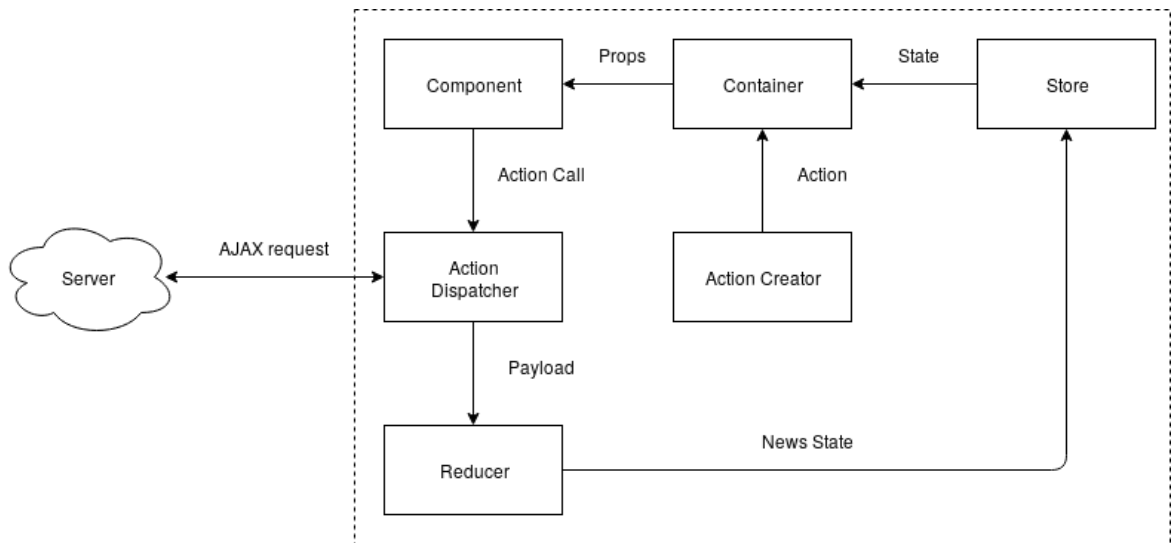
Bảng này dùng để quản lý danh sách người dùng hệ thống.

Thuộc tính	Loại	Ý nghĩa
ID	int(11)	ID của người dùng
Username	varchar(100)	Tên tài khoản
Password	Long	Mật khẩu
Email	varchar(100)	Địa chỉ email người dùng
Fullname	varchar(100)	Họ tên đầy đủ của người dùng
Phone	varchar(20)	Số điện thoại
UserTypeId	int(11)	ID phân loại người dùng

Bảng 3.4: Bảng User

## 3.9 Giao diện

Giao diện hệ thống được xây dựng sử dụng thư viện React, với kiến trúc Redux. Giao diện tương tác với hệ thống thông qua ajax request.



Hình 3.4: Kiến trúc giao diện hệ thống

### 3.9.1 Giao diện danh sách tin đã phân lớp

Tên	Loại	Mô tả
fetchSpam	Action	Truy xuất danh sách các tin đã phân lớp
sendFeedback	Action	Gửi phản hồi người dùng về label của tin đã phân lớp
spamList	State	Danh sách các tin đã phân lớp

Bảng 3.5: Bảng các thuộc tính

Tên	Loại	Mô tả
Date	Date Picker	Chọn ngày để lấy danh sách tin đã phân lớp
SpamTable	Table	Hiển thị danh sách các tin đã phân lớp
FeedbackBox	Select	Chọn và gửi phản hồi về label của tin đã phân lớp

Bảng 3.6: Bảng các đối tượng hiển thị

### 3.9.2 Giao diện phân lớp tin

Tên	Loại	Mô tả
fetchLabels	Action	Gửi danh sách các tin cần phân lớp và lấy về các label tương ứng
spamLabels	State	Danh sách các tin và label tương ứng

Bảng 3.7: Bảng các thuộc tính

Tên	Loại	Mô tả
InputTable	Table	Bảng chứa các tin cần hoặc đã phân lớp
DatatypeMenu	Tabs	Chuyển kiểu dữ liệu của input: text hoặc URL
ClassifyButton	Button	Thực hiện phân lớp các input
InputButton	Button	Hiện thị input form
InputForm	Form, Popup	Form để thêm input mới
ContentText	Input	Nội dung input
ExpectedLabel	Select	Label mong đợi của input
ConfirmButton	Button	Thêm input mới vào table của tab hiện tại
ImportButton	Button	Truyền dữ liệu input từ file
ClearAllButton	Button	Xóa hết dữ liệu input từ table của tab hiện tại
DeleteButton	Button	Xóa một dòng input trên bảng

Bảng 3.8: Bảng các đối tượng hiển thị

### 3.9.3 Giao diện thống kê dữ liệu phân lớp

Tên	Loại	Mô tả
fetchSpamStatistics	Action	Truy xuất dữ liệu thống kê phân lớp
spamStatistics	State	Dữ liệu thống kê phân lớp

Bảng 3.9: Bảng các thuộc tính

Tên	Loại	Mô tả
DateRange	Select	Chọn khung thời gian để lấy dữ liệu thống kê
ChartsSlider	Slider	Danh sách các đồ thị hiển thị dữ liệu thống kê

Bảng 3.10: Bảng các đối tượng hiển thị

## 3.10 Kết quả

Hệ thống đã hoàn thiện các chức năng: lọc rác tin tức trên Crawler, hiển thị danh sách tin đã qua phân lớp bằng bộ lọc rác, bộ phân lớp lọc rác thủ công, thống kê dữ liệu đã phân lớp. Dưới đây là một số hình ảnh của hệ thống: =====

## 3.11 Kết quả

Hệ thống đã hoàn thiện các chức năng: Thu thập dữ liệu từ trang tin tức, điều khiển chạy luồng của thuật toán phân loại tin nóng, và hiển thị thống kê cho biên tập

viên, hệ thống còn cung cấp giao diện phân loại tin tức bằng url hoặc title của tin tức. Dưới đây là một số hình ảnh của hệ thống: »»» > Minh


**Classified News**

Date  
15-12-2017


#	Content	Label	Post Date	Source	Editor's Feedback
1	<a href="#">Thông báo giá VLXD tại TP. Hà Nội quý III/2017 (P4 và hết)</a>	Không rác	15-12-2017	giacavattu.com.vn	<input type="text"/>
2	<a href="#">Số liệu thống kê hàng hóa xuất, nhập khẩu kỳ 2 tháng 11/2017</a>	Không rác	15-12-2017	giacavattu.com.vn	<input type="text"/>
3	<a href="#">Tham khảo giá xe ô tô tháng 11, 12/2017</a>	Không rác	15-12-2017	giacavattu.com.vn	<input type="text"/>
4	<a href="#">Tham khảo giá NK thép không hợp kim thị trường Hàn Quốc từ 28/11 - 06/12/2017</a>	Không rác	15-12-2017	giacavattu.com.vn	<input type="text"/>
5	<a href="#">Cửa nhựa, cửa nhôm</a>	Không rác	15-12-2017	giacavattu.com.vn	<input type="text"/>

Previous 1 2 3 ... 6974 6975 6976 Next


Hình 3.5: Giao diện danh sách tin đã phân lớp



Hình 3.6: Giao diện thống kê biểu đồ thứ 1 và thứ 2



Hình 3.7: Giao diện thống kê biểu đồ thứ 3



Hình 3.8: Giao diện thống kê biểu đồ thứ 4

**Spam Filter**

Text		URL		
#	Content	Label	Expected Label	Control
1	5 thủ thuật Excel	Rác (Chia sẻ)	Rác	Delete
2	5 món ăn ngon ngày hè	Rác (Chia sẻ)	Rác	Delete
3	Vợ chồng chia tay	Rác (Chia sẻ)	Rác	Delete

Classify Classify by Doc2Vec
Import + Input × Clear all

Hình 3.9: Giao diện bộ phân lớp tin tức



---

## 3.12 Kết chương

Chương này đã trình bày về các thành phần chính hệ thống, kiến trúc phân tầng, các hệ cơ sở dữ liệu được sử dụng và cách tổ chức, cùng một số kết quả cài đặt hệ thống.

## Chương 4

# THỰC NGHIỆM VÀ ĐÁNH GIÁ

### 4.1 Mở đầu

Mục đích của chương này là trình bày kết quả huấn luyện các thuật toán phân lớp trên bộ dữ liệu thu thập được. Qua đó đánh giá, nhận định và so sánh các thuật toán phân lớp.

### 4.2 Tổng quan về bộ dữ liệu

Bộ dữ liệu gồm các bài viết từ các trang báo điện tử Việt Nam. Dữ liệu được lấy về từ cơ sở dữ liệu tin tức của công ty VCCorp. Dữ liệu thu thập được được sànlọc thông qua một tập các từ khóa đã được định nghĩa trước.

Mỗi mẫu tin bao gồm các thông tin như sau: tựa đề tin, nội dung tin, mô tả tin, ngày đăng tin, và nguồn tin.

Bộ dữ liệu huấn luyện gồm 15,612 tin tiếng Việt, được thu thập và sànlọc trong khoảng thời gian từ.

Dữ liệu thống kê cho tập dữ liệu sử dụng để train các model:

Dữ liệu gán nhãn	Số lượng
Không rác	7331
Rác	8281
Tổng	15612

Bảng 4.1: Thống kê dữ liệu gán nhãn

---

Dữ liệu gắn nhãn	Số lượng
Quảng cáo	4627
Chia sẻ	3279
Tuyển dụng	375
Tổng	8281

Bảng 4.2: Thống kê loại rác

Chia sẻ	thủ thuật, mẹo, tình cảm, chia tay, món ăn, ngon, tâm sự
Tuyển dụng	việc làm, tuyển dụng, cộng tác viên, lao động
Quảng cáo	giảm giá, khuyến mãi, trúng thưởng

Bảng 4.3: Danh sách từ khóa để thu thập dữ liệu

Bộ dữ liệu có thể được tải về từ địa chỉ: [https://drive.google.com/open?id=1xZVBcaVtZAmQ4xU0KKPvB5ZRAUoKc2\\_v](https://drive.google.com/open?id=1xZVBcaVtZAmQ4xU0KKPvB5ZRAUoKc2_v)

## 4.3 Thiết lập thực nghiệm, cách đánh giá

Sử dụng 3 thuật toán phân lớp: thuật toán Naive Bayes, thuật toán J48, thuật toán Support Vector Machine.

Ta đánh giá và so sánh kết quả về thời gian xử lý và chất lượng phân lớp thông qua một số độ đo đã trình bày ở mục 2.6: Precision, Recall, F-Measure, ROC Area, confusion matrix.

## 4.4 Kết quả thực nghiệm

### 4.4.1 Kết quả train model phân loại tin tức

Dưới đây là kết quả các thuật toán và kết quả của một số độ đo :

---

#### 4.4.1.1 Kết quả dựa trên nội dung của tin của tập mẫu

Dữ liệu gán nhãn	Số lượng
Mẫu dữ liệu	15612
Số chiều	111363
Cross-validation:	10

Bảng 4.4: Thông số cơ bản của tập train

Time build model(seconds):		
SVM	NaiveBayes	J48
382.85	853.67	43530.21

Bảng 4.5: Thời gian train model

Class	Precision			Recall			F-Measure			ROC Area		
	J48	SVM	NaiveBayes	J48	SVM	NaiveBayes	J48	SVM	NaiveBayes	J48	SVM	NaiveBayes
Rác	0.845	0.876	0.847	0.838	0.915	0.874	0.842	0.895	0.860	0.823	0.884	0.854
Tin	0.819	0.898	0.852	0.827	0.854	0.821	0.823	0.876	0.836	0.823	0.884	0.871
	0.832	0.887	0.849	0.833	0.886	0.849	0.832	0.886	0.849	0.823	0.884	0.862

Bảng 4.6: Kết quả train model dựa trên một số độ đo

---

#### 4.4.1.2 Kết quả dựa trên tiêu đề của tin của tập mẫu

Dưới đây là kết quả các thuật toán và kết quả của một số độ đo :

Dữ liệu gán nhãn	Số lượng
Mẫu dữ liệu	15612
Số chiều	15133
Cross-validation:	10

Bảng 4.7: Thông số cơ bản của tập train

Time build model(seconds):		
SVM	NaiveBayes	J48
66.23	130.78	5895.41

Bảng 4.8: Thời gian train model

Class	Precision			Recall			F-Measure			ROC Area		
	J48	SVM	NaiveBayes	J48	SVM	NaiveBayes	J48	SVM	NaiveBayes	J48	SVM	NaiveBayes
Rác	0.845	0.876	0.847	0.838	0.915	0.874	0.842	0.895	0.860	0.823	0.884	0.854
Tin	0.819	0.898	0.852	0.827	0.854	0.821	0.823	0.876	0.836	0.823	0.884	0.871
	0.832	0.887	0.849	0.833	0.886	0.849	0.832	0.886	0.849	0.823	0.884	0.862

Bảng 4.9: Kết quả train model dựa trên một số độ đo

---

#### 4.4.2 Kết quả train model phân loại loại tin rác

Dữ liệu gán nhãn	Số lượng
Mẫu dữ liệu	8281
Số chiều	9526
Cross-validation:	10

Bảng 4.10: Thông số cơ bản của tập train

Time build model(seconds):		
SVM	NaiveBayes	J48
14.46	19.39	590.78

Bảng 4.11: Thời gian train model



Class	Precision			Recall			F-Measure			ROC Area		
	NaiveBayes	J48	SVM	NaiveBayes	J48	SVM	NaiveBayes	J48	SVM	NaiveBayes	J48	SVM
Chia sẻ	0.97	0.952	0.96	0.730	0.985	0.986	0.833	0.968	0.973	0.973	0.978	0.980
Quảng cáo	0.931	0.990	0.99	0.945	0.968	0.975	0.938	0.979	0.982	0.962	0.980	0.981
Tuyển dụng	0.335	0.989	1	0.992	0.952	0.955	0.5	0.970	0.977	0.954	0.987	0.977
	0.919	0.975	0.979	0.862	0.974	0.979	0.877	0.974	0.979	0.966	0.980	0.981

Bảng 4.12: Kết quả train model dựa trên một số độ đo

---

## 4.5 Nhận xét

### 4.5.1 Nhận định về các thuật toán phân lớp cho bài toán

Dựa vào bảng 4.6, 4.9 và 4.12, ta thấy rằng với độ đo và tập dữ liệu mẫu, thuật toán Support Vector Machine cho kết quả tốt với mọi độ đo so với thuật toán Naive Bayes và J48.

Dựa vào bảng 4.5, 4.8 và 4.11, ta thấy rằng thời gian để train model cho thuật toán Support Vector Machine tốn ít thời gian hơn thuật toán Naive Bayes và J48.

## 4.6 Kết chương

Qua các kết quả thử nghiệm, chương này đã thể hiện được một số tính chất của các thuật toán được đánh giá như thời gian train, một số độ đo thường dùng để đánh giá một hệ phân lớp. Ta thấy thuật toán SVM có thời gian train nhanh trong khi vẫn giữ được độ chính xác tốt so với thuật toán Naive Bayes và J48. Riêng thuật toán J48 có hạn chế về thời gian train quá lớn so với hai thuật toán còn lại.

# KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

## Kết quả đạt được

Mục tiêu chính của đề tài là xây dựng hệ thống phát hiện tin nóng để hỗ trợ biên tập viên trong việc viết bài. Một số nội dung thực hiện được đề ra ban đầu là: tìm hiểu bài toán liên quan, thu thập dữ liệu, cài đặt và đánh giá một số thuật toán, và xây dựng hệ thống.

Sau quá trình nghiên cứu và thực hiện, khóa luận đã thu được một số kết quả sau:

- Kiến thức:
  - Tìm hiểu về bài toán phát hiện tin tức, tin nóng trên dữ liệu từ mạng xã hội.
- Sản phẩm:
  - Thu thập bộ dữ liệu gồm các bài đăng tiếng Việt từ nguồn Twitter.
  - Khảo sát và đánh giá các phương pháp phát hiện tin nóng dựa trên gom cụm: k-Nearest Neighbor, Boost Named Entity, Locality Sensitive Hashing.
  - Xây dựng được hệ thống có khả năng nhận biết tin nóng, đang được triển khai tại công ty VCCorp.

## Hướng phát triển

Tuy hệ thống đạt được kết quả tương đối khá tốt trong việc phát hiện các sự kiện, cần cải thiện độ chính xác của thuật toán thông qua việc cân chỉnh kỹ hơn các thông

---

số, đồng thời xem xét tìm hiểu thêm và so sánh với các phương pháp khác.

Trong tương lai hệ thống cần lấy thêm dữ liệu từ các nguồn khác như Facebook và các trang báo mạng để làm giàu nguồn tin. Thêm các chức năng tiện ích cho biên tập viên như thống kê dữ liệu tổng quát lẫn chi tiết, cung cấp cho biên tập viên nhiều góc nhìn về sự kiện hơn.

# TÀI LIỆU THAM KHẢO

- [1] An K. Le. Vietnamese hot news detection from twitter. chapter The Hot News Detection Problem and Approaches, pages 6–26. Ho Chi Minh, Vietnam, 2017. [6](#)
- [2] Niklas Zechner. The past, present and future of text classification. Intelligence and Security Informatics Conference (EISIC), 2013 European. IEEE, 2013. [7](#)
- [3] Mehran Sahami, Susan T. Dumais, David Heckerman, and Eric Horvitz. A bayesian approach to filtering junk e-mail. 1998. [8](#)
- [4] Zoltán Gyöngyi, Hector Garcia-Molina, and Jan Pedersen. Combating web spam with trustrank. In *Proceedings of the Thirtieth International Conference on Very Large Data Bases - Volume 30*, VLDB '04, pages 576–587. VLDB Endowment, 2004. [8](#)
- [5] Anand Rajaraman and Jeffrey David Ullman. *Mining of Massive Datasets*. Cambridge University Press, 2011. [9](#)
- [6] Joeran Beel, Bela Gipp, Stefan Langer, and Corinna Breitingner. Research-paper recommender systems: a literature survey. *International Journal on Digital Libraries*, 17(4):305–338, Nov 2016. [9](#)
- [7] Tomas Mikolov, Kai Chen, G.s Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space. 2013, 01 2013. [9](#)
- [8] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, Sep 1995. [10](#)

- 
- [9] S. Phuvipadawat and T. Murata. Breaking news detection and tracking in twitter. In *2010 IEEE/WIC/ACM International Conference on Web Intelligence and Intelligent Agent Technology*, volume 3, pages 120–123, Aug 2010. [13](#), [22](#)
- [10] Piotr Indyk and Rameev Motwani. Approximate nearest neighbors: Towards removing the curse of dimensionality. In *Proceedings of the Thirtieth Annual ACM Symposium on Theory of Computing*, STOC '98, pages 604–613, New York, NY, USA, 1998. ACM. [16](#)
- [11] Saša Petrović, Miles Osborne, and Victor Lavrenko. Streaming first story detection with application to twitter. In *Human Language Technologies: The 2010 Annual Conference of the North American Chapter of the Association for Computational Linguistics*, HLT '10, pages 181–189, Stroudsburg, PA, USA, 2010. Association for Computational Linguistics. [18](#)
- [12] P.N. Tan, M. Steinbach, and V. Kumar. *Introduction to Data Mining*. Pearson Education, Limited, 2014. [19](#)
- [13] J. C. Dunn. A fuzzy relative of the isodata process and its use in detecting compact well-separated clusters. *Journal of Cybernetics*, 3(3):32–57, 1973. [20](#)

# Phụ lục. Giới thiệu về thư viện

## React và kiến trúc Redux

### Giới thiệu React

React (hay ReactJS) là một thư viện JavaScript được dùng để xây dựng giao diện người dùng. React được phát triển bởi Facebook, Instagram và cộng đồng các nhà phát triển và các doanh nghiệp. React cho phép các nhà phát triển xây dựng các ứng dụng web có thể thay đổi trạng thái mà không cần phải tải lại nội dung trang. Vì đặc tính này React thường được sử dụng để xây dựng các ứng dụng web đơn trang. Do bản thân React chỉ là một thư viện, nên nhà phát triển có thể tích hợp React vào các hệ thống kiến trúc MVC hoặc các framework giao diện người dùng khác như AngularJS.

Một đối tượng trong React được gọi là một component. Mỗi component có thể được tạo ra từ các component khác. Mỗi component có 2 thành phần chính cần quan tâm:

- *props*: là đối tượng chứa các tham số được tạo ra vào lúc khởi tạo

Lucene lưu trữ dữ liệu ở dạng chỉ mục ngược (inverted index), cho phép tìm kiếm các đối tượng văn bản dựa trên từ khóa một cách nhanh chóng. Một đối tượng văn bản trong Lucene được gọi là Document. Mỗi Document có một hoặc nhiều Field, ứng với các thuộc tính của Document đó. Một bài viết hay một trang web có thể là một Document, với các Field như: tiêu đề, nội dung, tác giả, ngày đăng,...

Một số class chính của thư viện:

- Analyzer và các class con: có nhiệm vụ phân tích dữ liệu văn bản thành những token/term trước khi ghi vào index. Một số class con như StandardAnalyzer,

---

WhitespaceAnalyzer, SimpleAnalyzer, KeywordAnalyzer.

- IndexWriter: nhận luồng dữ liệu đã tokenize bằng Analyzer và ghi vào index.
- IndexReader, IndexSearcher: đọc và tìm kiếm trên index đã tạo từ trước, ngoài ra cung cấp các thông tin khác từ index như danh sách term, tần số của term trong một Document, trong toàn bộ dữ liệu.
- Query và các class con: dùng để xây dựng câu truy vấn và truyền vào IndexSearcher để thực hiện tìm kiếm. Một số class con như TermQuery, RangeQuery, Boolean Query.

Hệ thống chủ yếu sử dụng Lucene hỗ trợ trong bước tiền xử lý dữ liệu, nhằm tính và biểu diễn các bài viết ở dạng vector tf-idf, thông qua các thông tin về tần số term trong index.

## Sử dụng Lucene trong Java

### Tạo IndexWriter

Để ghi dữ liệu vào Lucene index, ta cần tạo IndexWriter như sau:

```
indexDirectory = FSDirectory.open(new File(indexDir));
analyzer = new StandardAnalyzer(Version.LUCENE_36,
    Collections.emptySet());
IndexWriterConfig config = new
    IndexWriterConfig(Version.LUCENE_36, analyzer);
config.setOpenMode(OpenMode.CREATE);
IndexWriter writer = new IndexWriter(indexDirectory, config);
```

### Thêm một document vào index

Giả sử ta có một tweet với ID là "001", nội dung là "Tai nạn kinh hoàng khi xe tai mat phanh", dưới đây là cách tạo và thêm vào index document với 2 field tương ứng



---

là "tweetID" và "tweetContent".

```
Field tweetID = new Field("tweetID", "001", Field.Store.YES,
    Field.Index.NO);

Field tweetContent = new Field("tweetContent", "Tai nan kinh hoang
    khi xe tai mat phanh", Field.Store.YES, Field.Index.ANALYZED,
    Field.TermVector.YES);

Document lucenceDocument = new Document();

lucenceDocument.add(tweetID);

lucenceDocument.add(tweetContent);

writer.addDocument(luceneDocument);
```

## Đọc dữ liệu từ index

Sau khi tạo index, ta có thể đọc thông tin trong index thông qua IndexReader hoặc IndexSearcher.

```
IndexReader reader = IndexReader.open(indexDir);

IndexSearcher searcher = new IndexSearcher(reader);
```

Cách tính giá trị **idf** cho tất cả term trong field "tweetContent" trong bộ dữ liệu:

```
int docCount = reader.numDocs();

TermEnum listOfTerms = reader.terms();

TreeMap<String, Double> idfVector = new TreeMap<String, Double>();

while (listOfTerms.next()) {

    String currentTerm = listOfTerms.term().text();

    int docFreq = searcher.docFreq(new Term("tweetContent",
        currentTerm));

    double idf = 1 + Math.log((double) docCount / docFreq);

    idfVector.put(currentTerm, idf);

}
```

---

Cách tính vector tf-idf cho document thứ *i* trong index:

```
TermFreqVector tfv = reader.getTermFreqVector(i, "tweetContent");
String[] termList = tfv.getTerms(); //list of terms in this
    document
int[] termFreqList = tfv.getTermFrequencies();
int totalTermCount = 0;
LinkedHashMap<String, Double> tfidfVector = new
    LinkedHashMap<String, Double>();

// calculate (total) term count in document i
for (int temp : termFreqList) {
    totalTermCount += temp;
}

// loop through all term in doc i and calculate tfidf vector
int uniqueTermCount = termList.length;
for (int j = 0; j < uniqueTermCount; j++) {
    if (termFreqList[j] != 0 && idfVector.containsKey(termList[j])){
        double tfidf = ((double)termFreqList[j] / totalTermCount)
            * idfVector.get(termList[j]);
        tfidfVector.put(termList[j], tfidf);
    }
}
```